Министерство образования и науки Российской Федерации

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. БАУМАНА

Факультет «Информатика и системы управления»

Кафедра «Системы обработки информации и управления» (ИУ5)

ДИСЦИПЛИНА: «Технологии машинного обучения»

Отчет по лабораторной работе №3
«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Выполнила:

Студентка группы ИУ5-61Б

Мартынова Д.П.

Преподаватель:

Гапанюк Ю.Е.

Москва, 2020 г.

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:

- обработку пропусков в данных;
- кодирование категориальных признаков;
- масштабирование данных.

Выполнение ЛР:

Загрузка и первичный анализ данных

In [32]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

In [33]:
```
# используем выборку, связанную с коронавирусом
data = pd.read_csv('COVID19_line_list_data.csv', sep=",")
```

In [34]:
```
data.shape
```

Out[34]:
```
(1085, 27)
```

In [35]:
```
data.dtypes
```

Out[35]:
```
id                        int64
case_in_country         float64
reporting date           object
Unnamed: 3              float64
summary                  object
location                 object
country                  object
gender                   object
age                     float64
symptom_onset            object
If_onset_approximated   float64
hosp_visit_date          object
exposure_start           object
exposure_end             object
visiting Wuhan            int64
from Wuhan              float64
death                    object
recovered                object
symptom                  object
source                   object
link                     object
Unnamed: 21             float64
Unnamed: 22             float64
Unnamed: 23             float64
Unnamed: 24             float64
Unnamed: 25             float64
Unnamed: 26             float64
dtype: object
```

In [36]:
```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[36]:
```
id                          0
case_in_country           197
reporting date              1
Unnamed: 3               1085
summary                     5
location                    0
country                     0
gender                    183
age                       242
symptom_onset             522
If_onset_approximated     525
hosp_visit_date           578
exposure_start            957
exposure_end              744
visiting Wuhan              0
from Wuhan                  4
death                       0
recovered                   0
symptom                   815
source                      0
link                        0
Unnamed: 21              1085
Unnamed: 22              1085
Unnamed: 23              1085
Unnamed: 24              1085
Unnamed: 25              1085
Unnamed: 26              1085
dtype: int64
```

In [37]:
```
#удалим полностью пустые колонки
dat = data.dropna(axis=1, how='all')
dat.shape
```

Out[37]:
```
(1085, 20)
```

1. Обработка пропусков в данных

1.1. Простые стратегии - удаление или заполнение нулями

In [39]:
```
# Удаление колонок, содержащих пустые значения
data_new_1 = dat.dropna(axis=1, how='any')
(dat.shape, data_new_1.shape)
```

Out[39]:
```
((1085, 20), (1085, 8))
```

In [40]:
```
# Удаление строк, содержащих пустые значения
data_new_2 = dat.dropna(axis=0, how='any')
(dat.shape, data_new_2.shape)
```

Out[40]:
```
((1085, 20), (20, 20))
```

Заполнить все пропуски нулями не получится, потому что присутствуют категорийные столбцы

1.2. "Внедрение значений" - импьютация (imputation)

1.2.1. Обработка пропусков в числовых данных

In [118]:
```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
total_count = dat.shape[0]
for col in dat.columns:
    # Количество пустых значений
    temp_null_count = dat[dat[col].isnull()].shape[0]
    dt = str(dat[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

```
Колонка case_in_country. Тип данных float64. Количество пустых значений 197, 18.16%.
Колонка age. Тип данных float64. Количество пустых значений 242, 22.3%.
Колонка If_onset_approximated. Тип данных float64. Количество пустых значений 525, 48.39%.
Колонка from Wuhan. Тип данных float64. Количество пустых значений 4, 0.37%.
```

In [119]:
```
# Фильтр по колонкам с пропущенными значениями
data_num = dat[num_cols]
data_num
```

Out[119]:

	case_in_country	age	lf_onset_approximated	from Wuhan
0	NaN	66.0	0.0	0.0
1	NaN	56.0	0.0	1.0
2	NaN	46.0	0.0	1.0
3	NaN	60.0	NaN	0.0
4	NaN	58.0	NaN	0.0
...	...	...	...	...
1080	2.0	24.0	NaN	0.0
1081	1.0	35.0	NaN	0.0
1082	1.0	NaN	NaN	0.0
1083	1.0	NaN	NaN	0.0
1084	1.0	70.0	NaN	0.0

1085 rows × 4 columns

In [120]:
```
# Гистограмма по признакам
for col in data_num:
    plt.hist(dat[col], 50)
    plt.xlabel(col)
    plt.show()
```

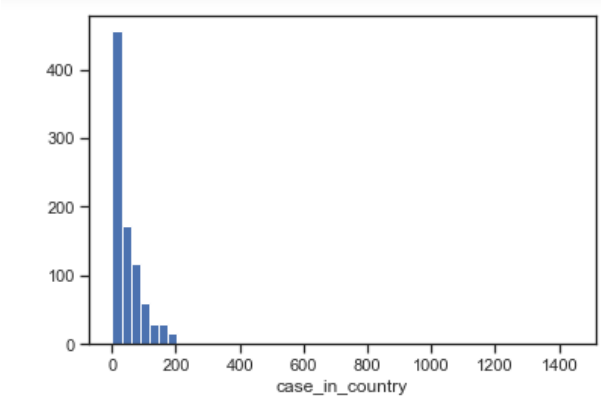

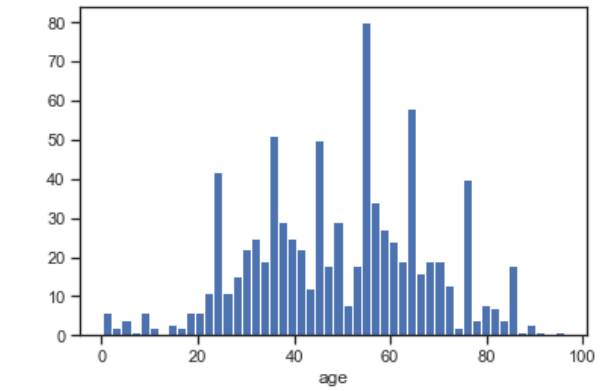

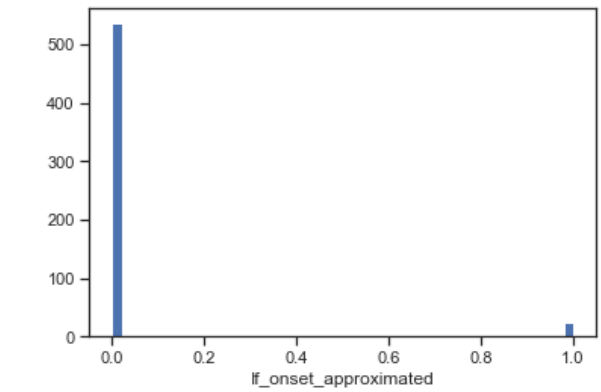

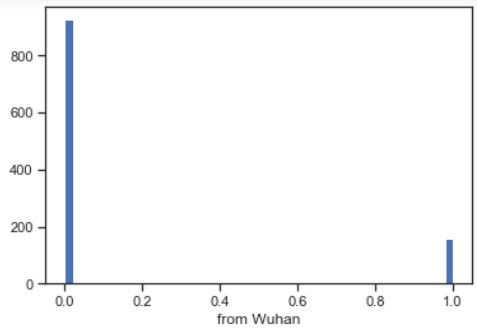

In [121]:
```
# Фильтр по пустым значениям поля MasVnrArea
dat[dat['age'].isnull()]
```

Out[121]:

	id	case_in_country	reporting date	summary	location	country	gender	age	symptom_onset	lf_onset_approximated	hosp_visit_date	exposure_start
22	23	NaN	1/22/2020	First confirmed imported COVID-19 pneumonia pa...	Shanxi	China	male	NaN	1/19/2020	0.0	1/20/2020	01/12/20
91	92	NaN	1/24/2020	new recovered imported COVID-19 pneumonia pati...	Beijing	China	female	NaN	NaN	NaN	NaN	NaN
116	117	NaN	1/25/2020	new recovered imported COVID-19	Beijing	China	male	NaN	NaN	NaN	NaN	NaN

In [122]:
```
# Запоминаем индексы строк с пустыми значениями
flt_index = dat[dat['age'].isnull()].index
flt_index
```

Out[122]:
```
Int64Index([  22,   91,  116,  145,  146,  147,  177,  201,  202,  204,
             ...
            1071, 1072, 1073, 1074, 1075, 1076, 1077, 1078, 1082, 1083],
           dtype='int64', length=242)
```

In [123]:
```
data_age = data_num[['age']]
data_age.head()
```

Out[123]:

	age
0	66.0
1	56.0
2	46.0
3	60.0
4	58.0

In [124]:
```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [125]:
```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_age)
mask_missing_values_only
```

Out[125]:
```
array([[False],
       [False],
       [False],
       ...,
       [ True],
       [ True],
       [False]])
```

In [126]:
```
strategies=['mean', 'median','most_frequent']
```

In [127]:
```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_age)
    return data_num_imp[mask_missing_values_only]
```

```
In [128]: strategies[0], test_num_impute(strategies[0])
```

```
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921, 49.48368921, 49.48368921, 49.48368921,
        49.48368921, 49.48368921]))
```

```
In [129]: strategies[1], test_num_impute(strategies[1])
```

```
Out[129]: ('median',
 array([51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51., 51.,
        51., 51., 51., 51., 51., 51., 51., 51.]))
```

```
In [130]: strategies[2], test_num_impute(strategies[2])
```

```
Out[130]: ('most_frequent',
 array([55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55., 55.,
        55., 55., 55., 55., 55., 55., 55., 55.]))
```

Заменим все пустые данные столбца 'age' на данные test_num_impute(strategies[0])

```
In [131]: new_age = pd.DataFrame({'id': flt_index,
                                  'age':test_num_impute(strategies[0])})
          new_age
```

Out[131]:

	id	age
0	22	49.483689
1	91	49.483689
2	116	49.483689
3	145	49.483689
4	146	49.483689
...	...	...
237	1076	49.483689
238	1077	49.483689
239	1078	49.483689
240	1082	49.483689
241	1083	49.483689

In [133]:
```
for index, row in new_age.iterrows():
    dat.loc[row['id'], 'age'] = row['age']
dat
```

Таким образом заменили все пустые значения в столбце age, на среднее значение по этому столбцу

1.2.2. Обработка пропусков в категориальных данных

In [135]:
```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in dat.columns:
    # Количество пустых значений
    temp_null_count = dat[dat[col].isnull()].shape[0]
    dt = str(dat[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
```

```
Колонка reporting date. Тип данных object. Количество пустых значений 1, 0.09%.
Колонка summary. Тип данных object. Количество пустых значений 5, 0.46%.
Колонка gender. Тип данных object. Количество пустых значений 183, 16.87%.
Колонка symptom_onset. Тип данных object. Количество пустых значений 522, 48.11%.
Колонка hosp_visit_date. Тип данных object. Количество пустых значений 578, 53.27%.
Колонка exposure_start. Тип данных object. Количество пустых значений 957, 88.2%.
Колонка exposure_end. Тип данных object. Количество пустых значений 744, 68.57%.
Колонка symptom. Тип данных object. Количество пустых значений 815, 75.12%.
```

In [139]:
```
cat_temp_data['gender'].unique()
```

Out[139]:
```
array(['male', 'female', nan], dtype=object)
```

In [140]:
```
cat_temp_data[cat_temp_data['gender'].isnull()].shape
```

Out[140]:
```
(183, 1)
```

In [141]:
```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[141]:
```
array([['male'],
       ['female'],
       ['male'],
       ...,
       ['male'],
       ['male'],
       ['male']], dtype=object)
```

In [142]:
```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

Out[142]:
```
array(['female', 'male'], dtype=object)
```

In [160]:
```
for index, row in cat_enc.iterrows():
    dat.loc[index, 'gender'] = row['c1']
dat
```

2. Преобразование категориальных признаков в числовые

In [147]:
```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

In [149]:
```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
cat_enc_le
```

Out[149]:
```
array([1, 0, 1, ..., 1, 1, 1])
```

In [166]:
```
gen_enc = pd.DataFrame({'gen':cat_enc_le})
for index, row in gen_enc.iterrows():
    dat.loc[index, 'gender'] = row['gen']
dat
```

```
C:\Users\Dasik\anaconda3\lib\site-packages\pandas\core\indexing.py:965: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  self.obj[item] = s
```

Out[166]:

	id	case_in_country	reporting date	summary	location	country	gender	age	symptom_onset	If_onset_approximated	hosp_visit_date
0	1	NaN	1/20/2020	First confirmed imported COVID-19 pneumonia pa...	Shenzhen, Guangdong	China	1	66.000000	01/03/20	0.0	01/11/20
				First confirmed							

3. Масштабирование данных

3.1. MinMax масштабирование

In [167]:
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

In [168]:
```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['age']])
```

In [174]:
```
plt.hist(data['age'], 40)
plt.show()
```

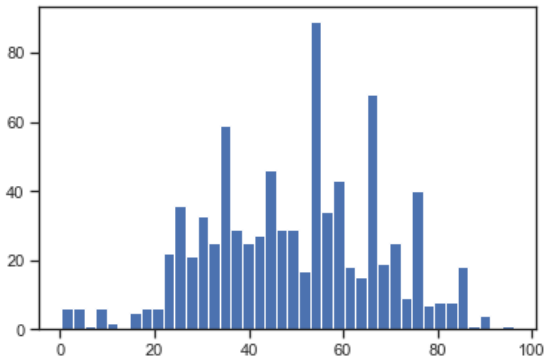

In [175]:
```
plt.hist(sc1_data, 40)
plt.show()
```

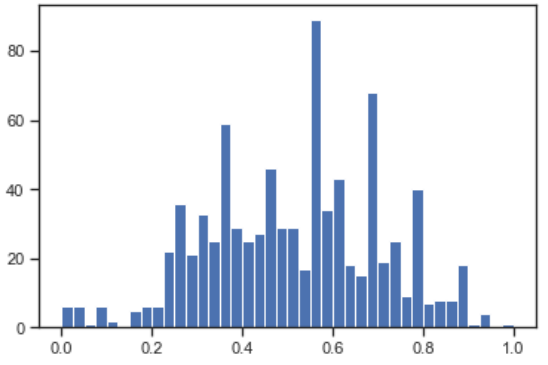

3.2. Нормализация данных

In [177]:
```
sc2 = Normalizer()
sc2_data = sc2.fit_transform(dat[['age']])
```

In [178]:
```
plt.hist(sc2_data, 40)
plt.show()
```