Министерство образования и науки Российской Федерации

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. БАУМАНА

Факультет «Информатика и системы управления»

Кафедра «Системы обработки информации и управления» (ИУ5)

ДИСЦИПЛИНА: «Технологии машинного обучения»

Отчет по рубежному контролю №1
«Технологии разведочного анализа и обработки данных»

Вариант №13

Выполнила:

Студентка группы ИУ5-61Б

Мартынова Д.П.

Преподаватель:

Гапанюк Ю.Е.

Москва, 2020 г.

Задание:

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

+ для пары произвольных колонок данных построить график "Диаграмма рассеяния"

Датасет: https://www.kaggle.com/noriuk/us-education-datasets-unification-project (файл states_all_extended.csv)

Выполнение РК:

In [39]:
```
import numpy as np
import pandas as pd
pd.set_option('display.max.columns', 100)
# to draw pictures in jupyter notebook
%matplotlib inline
import matplotlib.pyplot as plt
import seaborn as sns
# we don't like warnings
# you can comment the following 2 lines if you'd like to
import warnings
warnings.filterwarnings('ignore')
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [40]:
```
data = pd.read_csv('states_all_extended.csv')
data.head()
```

Out[40]:

	PRIMARY_KEY	STATE	YEAR	ENROLL	TOTAL_REVENUE	FEDERAL_REVENUE	STATE_REVENUE	LOCAL_
0	1992_ALABAMA	ALABAMA	1992	NaN	2678885.0	304177.0	1659028.0	715680.0
1	1992_ALASKA	ALASKA	1992	NaN	1049591.0	106780.0	720711.0	222100.0
2	1992_ARIZONA	ARIZONA	1992	NaN	3258079.0	297888.0	1369815.0	1590376
3	1992_ARKANSAS	ARKANSAS	1992	NaN	1711959.0	178571.0	958785.0	574603.0
4	1992_CALIFORNIA	CALIFORNIA	1992	NaN	26260025.0	2072470.0	16546514.0	7641041

5 rows × 230 columns

In [41]:
```
#посмотрим на типы колонок
data.dtypes
```

Out[41]:
```
PRIMARY_KEY             object
STATE                   object
YEAR                     int64
ENROLL                 float64
TOTAL_REVENUE          float64
                        ...
PK_WH_M                float64
AVG_MATH_4_SCORE       float64
AVG_MATH_8_SCORE       float64
AVG_READING_4_SCORE    float64
AVG_READING_8_SCORE    float64
Length: 230, dtype: object
```

In [42]:
```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[42]:
```
PRIMARY_KEY              0
STATE                    0
YEAR                     0
ENROLL                 694
TOTAL_REVENUE          643
                      ...
PK_WH_M               1524
AVG_MATH_4_SCORE      1383
AVG_MATH_8_SCORE      1387
AVG_READING_4_SCORE   1386
AVG_READING_8_SCORE   1421
Length: 230, dtype: int64
```

In [43]:
```
#размер df
total_count = data.shape[0]
```

In [44]:
```
# Выберем числовые колонки с пропущенными значениями
num_cols = []
total_count = data.shape[0]
for col in data.columns:
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_c
ount, temp_perc))
```

```
Колонка ENROLL. Тип данных float64. Количество пустых значений 694, 36.18%.
Колонка TOTAL_REVENUE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка FEDERAL_REVENUE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка STATE_REVENUE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка LOCAL_REVENUE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка TOTAL_EXPENDITURE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка INSTRUCTION_EXPENDITURE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка SUPPORT_SERVICES_EXPENDITURE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка OTHER_EXPENDITURE. Тип данных float64. Количество пустых значений 694, 36.18%.
Колонка CAPITAL_OUTLAY_EXPENDITURE. Тип данных float64. Количество пустых значений 643, 33.52%.
Колонка A_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G01_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G02_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G03_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G04_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G05_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G06_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G07_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G08_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G09_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G10_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G11_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка G12_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка KG_A_A. Тип данных float64. Количество пустых значений 286, 14.91%.
Колонка PK_A_A. Тип данных float64. Количество пустых значений 376, 19.6%.
Колонка G01-G08_A_A. Тип данных float64. Количество пустых значений 898, 46.82%.
```

...

```
Колонка PK_TR_F. Тип данных float64. Количество пустых значений 1560, 81.33%.
Колонка PK_TR_M. Тип данных float64. Количество пустых значений 1560, 81.33%.
Колонка PK_WH_F. Тип данных float64. Количество пустых значений 1524, 79.46%.
Колонка PK_WH_M. Тип данных float64. Количество пустых значений 1524, 79.46%.
Колонка AVG_MATH_4_SCORE. Тип данных float64. Количество пустых значений 1383, 72.11%.
Колонка AVG_MATH_8_SCORE. Тип данных float64. Количество пустых значений 1387, 72.31%.
Колонка AVG_READING_4_SCORE. Тип данных float64. Количество пустых значений 1386, 72.26%.
Колонка AVG_READING_8_SCORE. Тип данных float64. Количество пустых значений 1421, 74.09%.
```

In [45]:
```
#Возьмем колонку Enroll
# Запоминаем индексы строк с пустыми значениями
flt_index = data[data['ENROLL'].isnull()].index
flt_index
```

Out[45]:
```
Int64Index([   0,    1,    2,    3,    4,    5,    6,    7,    8,    9,
                ...
            1908, 1909, 1910, 1911, 1912, 1913, 1914, 1915, 1916, 1917],
           dtype='int64', length=694)
```

In [46]:
```
data_enroll = data[num_cols][['ENROLL']]
data_enroll.head()
```

Out[46]:

	ENROLL
0	NaN
1	NaN
2	NaN
3	NaN
4	NaN

In [47]:
```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_enroll)
mask_missing_values_only
```

Out[47]:
```
array([[ True],
       [ True],
       [ True],
       ...,
       [ True],
       [ True],
       [ True]])
```

In [48]:
```
strategy='mean'
```

In [49]:
```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_enroll)
    return data_num_imp[mask_missing_values_only]
```

In [53]:
```
new_enroll = pd.DataFrame({'id': flt_index,
                           'ENROLL':test_num_impute('mean')})
new_enroll
```

Out[53]:

	id	ENROLL
0	0	917541.566176
1	1	917541.566176
2	2	917541.566176
3	3	917541.566176
4	4	917541.566176
...	...	...
689	1913	917541.566176
690	1914	917541.566176
691	1915	917541.566176
692	1916	917541.566176
693	1917	917541.566176

694 rows × 2 columns

In [55]:
```
for index, row in new_enroll.iterrows():
    data.loc[row['id'], 'ENROLL'] = row['ENROLL']
data
#очистили данные для колонки ENROLL
```

Out[55]:

	PRIMARY_KEY	STATE	YEAR	ENROLL	TOTAL_REVENUE	FEDERAL_REVENUE	STA1
0	1992_ALABAMA	ALABAMA	1992	917541.566176	2678885.0	304177.0	1659
1	1992_ALASKA	ALASKA	1992	917541.566176	1049591.0	106780.0	7207
2	1992_ARIZONA	ARIZONA	1992	917541.566176	3258079.0	297888.0	1369
3	1992_ARKANSAS	ARKANSAS	1992	917541.566176	1711959.0	178571.0	9587
4	1992_CALIFORNIA	CALIFORNIA	1992	917541.566176	26260025.0	2072470.0	1654
...	...	...	...	...	...	...	...
1913	2017_NORTH_DAKOTA	NORTH_DAKOTA	2017	917541.566176	NaN	NaN	NaN
1914	2017_RHODE_ISLAND	RHODE_ISLAND	2017	917541.566176	NaN	NaN	NaN
1915	2017_SOUTH_CAROLINA	SOUTH_CAROLINA	2017	917541.566176	NaN	NaN	NaN
1916	2017_SOUTH_DAKOTA	SOUTH_DAKOTA	2017	917541.566176	NaN	NaN	NaN
1917	2017_WEST_VIRGINIA	WEST_VIRGINIA	2017	917541.566176	NaN	NaN	NaN

1918 rows × 230 columns

In [59]:
```
# Выберем категориальные колонки с пропущенными значениями
cat_cols = []
for col in data.columns:
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_c
ount, temp_perc))
```

В данном датасете нет категорийных признаков с пропущенными данными, поэтому возбмем другой датасет и очистим категорийный признак там

In [76]:
```
data1 = pd.read_csv('COVID19_line_list_data.csv')
data1.head()
```

Out[76]:

	id	case_in_country	reporting date	Unnamed: 3	summary	location	country	gender	age	symptom_onset	If_onset_app
0	1	NaN	1/20/2020	NaN	First confirmed imported COVID-19 pneumonia pa...	Shenzhen, Guangdong	China	male	66.0	01/03/20	0.0
1	2	NaN	1/20/2020	NaN	First confirmed imported COVID-19 pneumonia pa...	Shanghai	China	female	56.0	1/15/2020	0.0
2	3	NaN	1/21/2020	NaN	First confirmed imported cases in Zhejiang: pa...	Zhejiang	China	male	46.0	01/04/20	0.0
3	4	NaN	1/21/2020	NaN	new confirmed imported COVID-19 pneumonia in T...	Tianjin	China	female	60.0	NaN	NaN
4	5	NaN	1/21/2020	NaN	new confirmed imported COVID-19 pneumonia in T...	Tianjin	China	male	58.0	NaN	NaN

In [77]:
```
#проверим наличие категорийных признаков в данно датасете
total_count1 = data1.shape[0]
cat_cols1 = []
for col in data1.columns:
    temp_null_count = data1[data1[col].isnull()].shape[0]
    dt = str(data1[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols1.append(col)
        temp_perc = round((temp_null_count / total_count1) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_c
ount, temp_perc))
```

```
Колонка reporting date. Тип данных object. Количество пустых значений 1, 0.09%.
Колонка summary. Тип данных object. Количество пустых значений 5, 0.46%.
Колонка gender. Тип данных object. Количество пустых значений 183, 16.87%.
Колонка symptom_onset. Тип данных object. Количество пустых значений 522, 48.11%.
Колонка hosp_visit_date. Тип данных object. Количество пустых значений 578, 53.27%.
Колонка exposure_start. Тип данных object. Количество пустых значений 957, 88.2%.
Колонка exposure_end. Тип данных object. Количество пустых значений 744, 68.57%.
Колонка symptom. Тип данных object. Количество пустых значений 815, 75.12%.
```

In [78]:
```
#для очистки возьмем столбец gender
cat_temp_data = data1[['gender']]
cat_temp_data.head()
```

Out[78]:

	gender
0	male
1	female
2	male
3	female
4	male

In [79]:
```
cat_temp_data['gender'].unique()
```

Out[79]:
```
array(['male', 'female', nan], dtype=object)
```

In [80]:
```
imp = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp = imp.fit_transform(cat_temp_data)
data_imp
```

Out[80]:
```
array([['male'],
       ['female'],
       ['male'],
       ...,
       ['male'],
       ['male'],
       ['male']], dtype=object)
```

In [81]:
```
# Пустые значения отсутствуют
np.unique(data_imp)
```

Out[81]:
```
array(['female', 'male'], dtype=object)
```

In [82]:
```
cat_enc = pd.DataFrame({'gender':data_imp.T[0]})
cat_enc
```

Out[82]:

	gender
0	male
1	female
2	male
3	female
4	male
...	...
1080	male
1081	male
1082	male
1083	male
1084	male

1085 rows × 1 columns

In [84]:
```
for index, row in cat_enc.iterrows():
    data1.loc[index, 'gender'] = row['gender']
data1
```

Out[84]:

	id	case_in_country	reporting date	Unnamed: 3	summary	location	country	gender	age	symptom_onset
0	1	NaN	1/20/2020	NaN	First confirmed imported COVID-19 pneumonia pa...	Shenzhen, Guangdong	China	male	66.0	01/03/20

1	2	NaN	1/20/2020	NaN	First confirmed imported COVID-19 pneumonia pa...	Shanghai	China	female	56.0	1/15/2020
2	3	NaN	1/21/2020	NaN	First confirmed imported cases in Zhejiang: pa...	Zhejiang	China	male	46.0	01/04/20
3	4	NaN	1/21/2020	NaN	new confirmed imported COVID-19 pneumonia in T...	Tianjin	China	female	60.0	NaN
4	5	NaN	1/21/2020	NaN	new confirmed imported COVID-19 pneumonia in T...	Tianjin	China	male	58.0	NaN
...	...	...	...	...	...	...	...	...	...	...
1080	1081	2.0	2/25/2020	NaN	new COVID-19 patient confirmed in Austria: 24,...	Innsbruck	Austria	male	24.0	NaN
1081	1082	1.0	2/24/2020	NaN	new COVID-19 patient confirmed in Afghanistan:...	Afghanistan	Afghanistan	male	35.0	NaN
1082	1083	1.0	2/26/2020	NaN	new COVID-19 patient confirmed in Algeria: mal...	Algeria	Algeria	male	NaN	NaN
1083	1084	1.0	2/25/2020	NaN	new COVID-19 patient confirmed in Croatia: mal...	Croatia	Croatia	male	NaN	NaN
1084	1085	1.0	2/25/2020	NaN	new COVID-19 patient confirmed in	Bern	Switzerland	male	70.0	2/17/2020

1085 rows × 27 columns

In [87]:
```
# диаграмма рассеяния для первого датасета для штата КАЛИФОРНИЯ
# зависимость года поступления и числа поступающих

calif_df = data[data['STATE'] == 'CALIFORNIA']
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='YEAR', y='ENROLL', data=calif_df)
```

Out[87]: <matplotlib.axes._subplots.AxesSubplot at 0xc2d2b88>

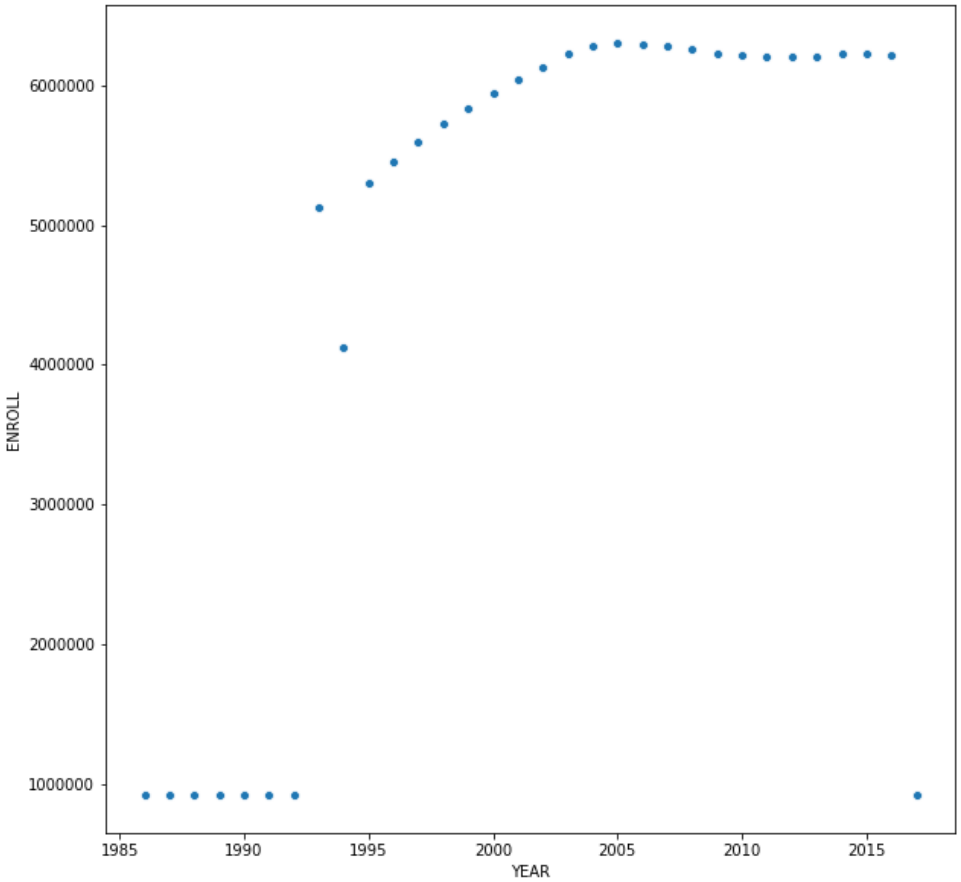

Таким образом для обработки пропусков в данных для количественного признака использовался метод импьютации средними значениями, а для категорийных признаков - импьютации наиболее частыми значениями. Для дальнейшего построения моделей можно в принципе использовать все столбцы, обработав предварительно пропуски, в зависимости от нужд исследований.